Ανάλυση Δεδομένων

– ΕΡΕΥΝΑ ΔΙΑΤΡΟΦΗΣ –

(Εργασία 3)

Διδάσκοντες: Ι. Ντζούφρας, Κ. Πατέρας

Φοιτητής

Ονοματεπώνυμο: Πασαπνοής Κωνσταντίνος
Αριθμός Μητρώου: 6200093
Έτος Σπουδών: 5ο

Ιούνιος 2025

Περιεχόμενα

1 Εισαγωγή **1**

2 Περιγραφική Στατιστική **2**

3 Σχέσεις ανά δύο **3**

4 Προβλεπτικά ή Ερμηνευτικά μοντέλα **5**

5 Συμπεράσματα **9**

6 Παράρτημα **9**

1 Εισαγωγή

Ο καρκίνος αποτελεί μία από τις πιο θανατηφόρες ασθένειες παγκοσμίως. Η ανάπτυξή του αποτελεί μια διαδικασία η οποία δεν έχει κατανοηθεί από τους επιστήμονες πλήρως και συνεχώς γίνονται έρευνες για την κατανόησή του. Ένας από τους βασικούς τρόπους πρόληψης εναντίον του, που έχουν ορίσει οι επιστήμονες, είναι μία σωστή και ισορροπημένη διατροφή. Σκοπός της παρούσας μελέτης είναι να βρούμε τη συσχέτιση μεταξύ της συγκέντρωσης ρετινόλης και β-καροτίνης στο πλάσμα με την εμφάνιση διαφόρων μορφών καρκίνου.

Το σετ δεδομένων της εργασίας προέρχεται από μία μεγάλη έρευνα που πραγματοποιήθηκε στις Ηνωμένες Πολιτείες της Αμερικής και περιέχει στοιχεία από 315 ασθενείς, τα οποία είναι κατανεμημένα σε 12 μεταβλητές.

Πίνακας 1: Πινάκας Δεδομένων

Μεταβλητή	**Περιγραφή**	**Τύπος**
`age`	Ηλικία (σε έτη)	Ποσοτική
`sex`	Φύλο (1: Άνδρας, 2: Γυναίκα)	Κατηγορική
`smk`	Καπνιστικές συνήθειες (1: Ποτέ, 2: Πρώην, 3: Νυν)	Κατηγορική
`BMI`	Δείκτης Μάζας Σώματος (kg/m^2)	Ποσοτική
`vituse`	Χρήση βιταμινών (1: Συχνά, 2: Όχι συχνά, 3: Όχι)	Κατηγορική
`calories`	Καθημερινή πρόσληψη θερμίδων	Ποσοτική
`fat`	Καθημερινή πρόσληψη λίπους (gr)	Ποσοτική
`fiber`	Καθημερινή πρόσληψη φυτικών ινών (gr)	Ποσοτική
`alcohol`	Κατανάλωση αλκοόλ ανά εβδομάδα (ποτά)	Ποσοτική
`cholest`	Καθημερινή πρόσληψη χοληστερόλης (mg)	Ποσοτική
`bplasma`	Συγκέντρωση βήτα-καροτίνης στο πλάσμα (ng/ml)	Ποσοτική
`rplasma`	Συγκέντρωση ρετινόλης στο πλάσμα (ng/ml)	Ποσοτική

2 Περιγραφική Στατιστική

Στο πλαίσιο της ανάλυσής μας, θα αξιοποιήσουμε το στατιστικό πακέτο της R, το οποίο μας επιτρέπει να πραγματοποιήσουμε στατιστικούς ελέγχους και να δημιουργήσουμε διαγράμματα που παρουσιάζουν με σαφήνεια τα αποτελέσματα. Αρχικά, τα δεδομένα βασίζονται σε μια έρευνα που περιελάμβανε 315 ασθενείς, με σκοπό να εξεταστεί η σχέση προσωπικών χαρακτηριστικών, διατροφικών συνηθειών και της συγκέντρωσης ρετινόλης και β-καροτίνης στο πλάσμα του αίματος.

Αναλύοντας τα δεδομένα μας, διαπιστώνουμε πως αποτελούνται από 12 διαφορετικές μεταβλητές, από τις οποίες οι τρεις είναι κατηγορικές και οι υπόλοιπες εννέα είναι ποσοτικές. Οι τρεις κατηγορικές (SEX, SMOKSTAT και VITUSE) έχουν καταγραφεί ως αριθμοί και γι' αυτό πρέπει να τις κατηγοριοποιήσουμε. Δηλαδή, για το φύλο των ασθενών δίνουμε τις τιμές: 1: ΑΝΔΡΑΣ, 2: ΓΥΝΑΙΚΑ· για τις καπνιστικές συνήθειες: 1: ΠΟΤΕ, 2: ΠΡΩΗΝ ΚΑΠΝΙΣΤΗΣ, 3: ΚΑΠΝΙΣΤΗΣ· και τέλος για τη χρήση βιταμινών: 1: ΝΑΙ - ΣΥΧΝΑ, 2: ΝΑΙ - ΟΧΙ ΣΥΧΝΑ, 3: ΟΧΙ.

Πίνακας 2: Περιγραφικά Μέτρα Κατηγορικών Μεταβλητών

Μεταβλητή - Κατηγορία	**Απόλυτη Συχνότητα**	**Σχετική Συχνότητα**
Φύλο (SEX)		
Άνδρας	42	0.134
Γυναίκα	272	0.866
Καπνιστική Συνήθεια (SMOKSTAT)		
Ποτέ	157	0.500
Πρώην καπνιστ-ής/-ρια	114	0.363
Καπνιστ-ής/-ρια	43	0.137
Χρήση Βιταμινών (VITUSE)		
Ναι – Συχνά	121	0.385
Ναι – Όχι συχνά	82	0.261
Όχι	111	0.354

Από τον Πίνακα 2 μπορούμε να εξάγουμε τα εξής συμπεράσματα: παρατηρούμε μια σημαντική ανισορροπία μεταξύ των δύο φύλων. Συγκεκριμένα, το 86,6% (n = 272) είναι γυναίκες, ενώ μόνο το 13,4% (n = 42) είναι άνδρες. Όσον αφορά τις καπνιστικές συνήθειες: το 50% των ατόμων δεν έχει καπνίσει ποτέ (n = 157), ενώ μόλις το 13,7% είναι νυν καπνιστές/καπνίστριες (n = 43). Κλείνοντας, στη χρήση βιταμινών, η κατανομή είναι σχετικά ισορροπημένη, αλλά φαίνεται μια μικρή τάση προς τη συχνή χρήση βιταμινών με ποσοστό 38,5% (n = 121).

Στη συνέχεια, θα μελετήσουμε τα περιγραφικά μέτρα των ποσοτικών μεταβλητών: τον μέσο, την τυπική απόκλιση, το πρώτο και το τρίτο τεταρτημόριο (Q1 και Q3), τη διάμεσο, την κυρτότητα, την ασυμμετρία και τον συντελεστή μεταβλητότητας (CV).

Πίνακας 3: Περιγραφικά Μέτρα Ποσοτικών Μεταβλητών

Μεταβλητή	**Μέσος**	**Τυπ. Απόκλιση**	**Q1**	**Διάμεσος**	**Q3**	**Κύρτωση**	**Ασυμμετρία**	**Cv**
AGE	50.10	14.58	39.00	47.50	62.00	-0.88	0.30	0.29
BMI	26.17	6.02	21.82	24.74	28.90	1.92	1.36	0.23
CALORIES	1798.24	680.85	1348.30	1672.50	2103.43	7.90	1.73	0.38
FAT	77.10	33.86	53.93	73.10	95.28	1.92	1.09	0.44
FIBER	12.81	5.33	9.20	12.10	15.60	2.40	1.14	0.42
ALCOHOL	3.29	12.34	0.00	0.30	3.20	215.77	13.67	3.75
CHOLESTE	242.69	132.14	154.95	207.50	308.88	3.28	1.46	0.54
BETAPLAS	189.86	183.29	89.50	139.00	230.50	16.73	3.53	0.97
RETPLAS	601.80	208.48	466.00	565.00	712.25	3.98	1.32	0.35

Παρατηρώντας τον Πίνακα 3, που παρουσιάζει τα περιγραφικά μέτρα των ποσοτικών μεταβλητών, συμπεραίνουμε πως η μέση ηλικία των ασθενών είναι 50,10 έτη με τυπική απόκλιση 14,58 έτη. Το 25% των συμμετεχόντων

ήταν κάτω από 39 έτη, το 50% ήταν κάτω από 47,5 έτη, ενώ το 75% δεν ήταν πάνω από 62 έτη. Επίσης, παρατηρούμε ότι ο δείκτης CV λαμβάνει τιμές μικρότερες από 0,3 για τις AGE και BMI, οπότε παρουσιάζουν ομοιογένεια. Για τις υπόλοιπες μεταβλητές CALORIES, FAT, FIBER, ALCOHOL, CHOLESTE, BETAPLAS, RETPLAS υπάρχει υψηλή ανομοιογένεια.

3 Σχέσεις ανά δύο

Μετά την περιγραφική ανάλυση, ακολουθεί η εξέταση των σχέσεων των μεταβλητών ανά δύο. Ξεκινώντας, εξετάζουμε αν οι ποσοτικές μεταβλητές ακολουθούν την κανονική κατανομή, εφαρμόζοντας τον έλεγχο Shapiro–Wilk. Τα αποτελέσματα έδειξαν ότι καμία από αυτές δεν παρουσιάζει κανονική κατανομή, καθώς όλες οι τιμές του p-value ήταν μικρότερες από 0,05 (Shapiro–Wilk $p < 0,05$).

Πίνακας 4: Πίνακας συσχετίσεων

	AGE	*BMI*	*CALORIES*	*FAT*	*FIBER*	*ALCOHOL*	*CHOLESTE*	*BETAPLAS*	*RETPLAS*
AGE									
BMI	0.060								
CALORIES	-0.196***	-0.016							
FAT	-0.164**	0.038	0.895***						
FIBER	0.026	-0.084	0.551***	0.317***					
ALCOHOL	-0.089	-0.220***	0.123*	0.057	0.089				
CHOLESTE	-0.123*	0.123*	0.689***	0.755***	0.223***	0.093			
BETAPLAS	0.158**	-0.296***	-0.054	-0.130*	0.193***	0.074	-0.142*		
RETPLAS	0.224***	0.046	-0.030	-0.073	-0.031	0.143*	-0.008	0.128*	

Computed correlation used spearman-method with listwise-deletion.

Από τον Πίνακα 4 παρατηρούμε πως η συγκέντρωση της β-καροτίνης παρουσιάζει στατιστικά σημαντική συσχέτιση με την ηλικία ($\rho = 0,158$), αλλά και με τις φυτικές ίνες που καταναλώνονται καθημερινά ($\rho = 0,193$). Αντίθετα, παρατηρήθηκε αρνητική συσχέτιση μεταξύ του Δείκτη Μάζας Σώματος και του λίπους που καταναλώνεται καθημερινά. Είναι εύκολο να συμπεράνουμε πως μία ισορροπημένη διατροφή, πλούσια σε φυτικές ίνες, σχετίζεται θετικά με τα επίπεδα της β-καροτίνης στο πλάσμα του αίματος. Αντίστοιχα, η ρετινόλη παρουσιάζει θετική συσχέτιση με την ηλικία ($\rho = 0,224$) και με την κατανάλωση αλκοόλ ($\rho = 0,143$). Κατόπιν, εκτελέσαμε ελέγχους με όλες τις κατηγορικές μεταβλητές. Εφαρμόζοντας τον μη παραμετρικό έλεγχο Wilcoxon, ψάξαμε να βρούμε εάν τα επίπεδα της βήτα-καροτίνης και ρετινόλης διαφέρουν ανάμεσα στα δύο φύλα. Τα αποτελέσματα του ελέγχου έδειξαν πως διαφέρουν σημαντικά ($W = 6988$, p-value = 0,01985) για τη ρετινόλη και ($W = 4368$, p-value = 0,01415) για τη βήτα-καροτίνη.

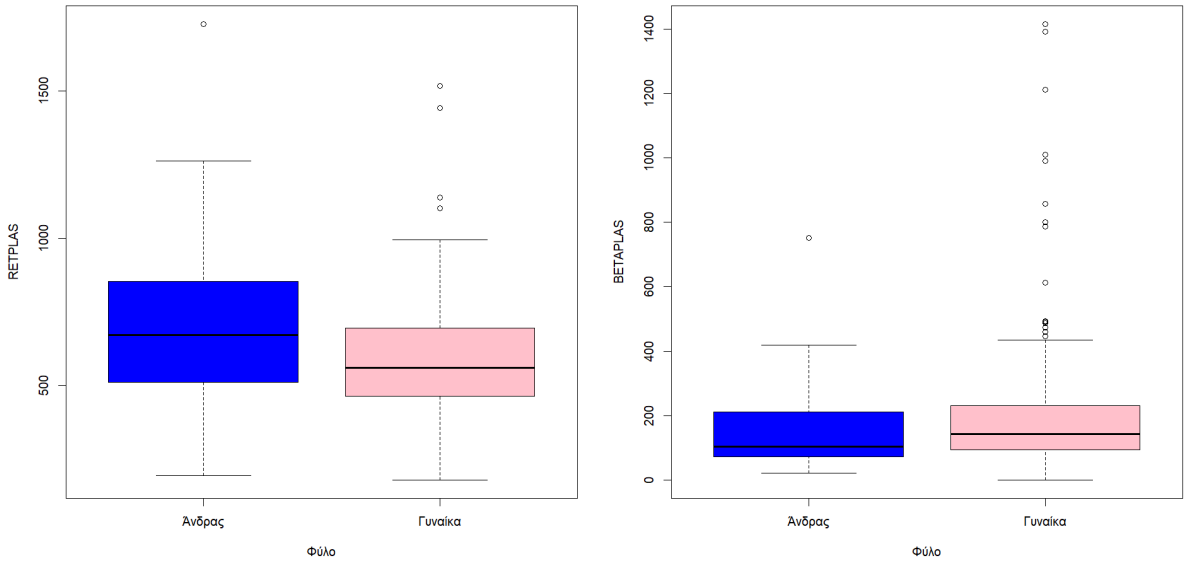

Διάγραμμα 1: Boxplot για τις μεταβλητές RETPLAS και BETAPLAS ανά φύλο

Στην πορεία ελέγξαμε εάν τα επίπεδα της βήτα-καροτίνης και ρετινόλης διαφοροποιούνται ανάμεσα σε ασθενείς που έχουν διαφορετικές καπνιστικές συνήθειες αλλά και κάνουν χρήση βιταμινών στην καθημερινότητά τους. Με τη βοήθεια του μη παραμετρικού ελέγχου Kruskal–Wallis παρατηρούμε πως η βήτα-καροτίνη και η ρετινόλη διαφοροποιούνται σημαντικά για τα τρία επίπεδα των καπνιστικών συνηθειών των ασθενών (chi-squared = 6,2555, p-value = 0,04382) και (chi-squared = 12,603, p-value = 0,001833).

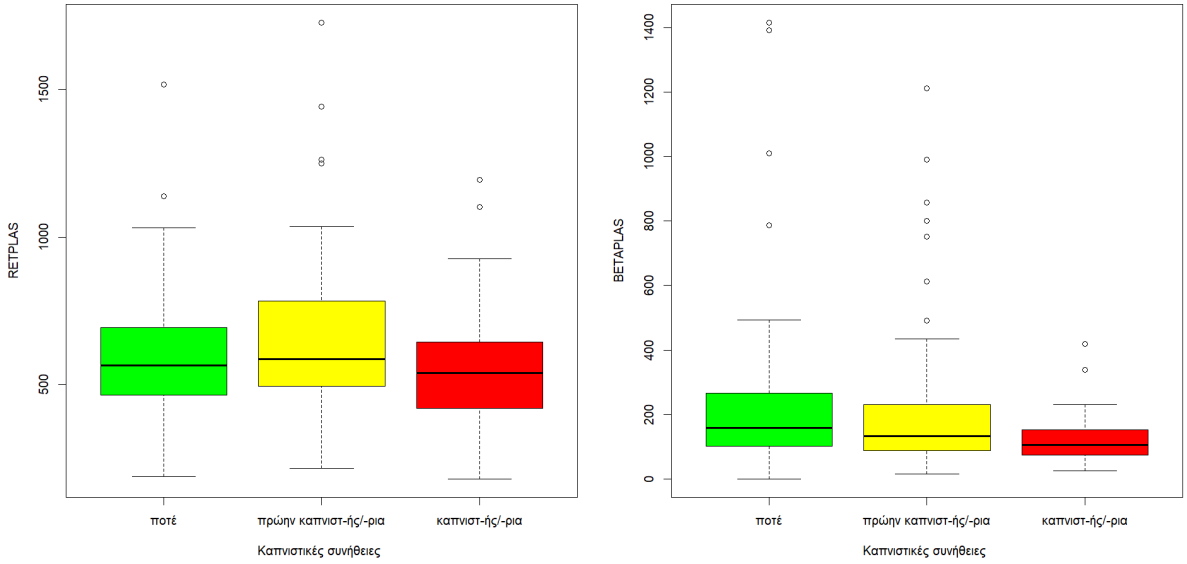

Διάγραμμα 2: Boxplot για τις μεταβλητές RETPLAS και BETAPLAS ανά καπνιστικές συνήθειες

Αντίθετα, τα τρία επίπεδα στη λήψη βιταμινών δεν επηρεάζουν τα επίπεδα της ρετινόλης στο πλάσμα (chi-squared = 0,27165, p-value = 0,873), αλλά επηρεάζουν τα επίπεδα της βήτα-καροτίνης (chi-squared = 18,204, df = 2, p-value = 0,0001114).

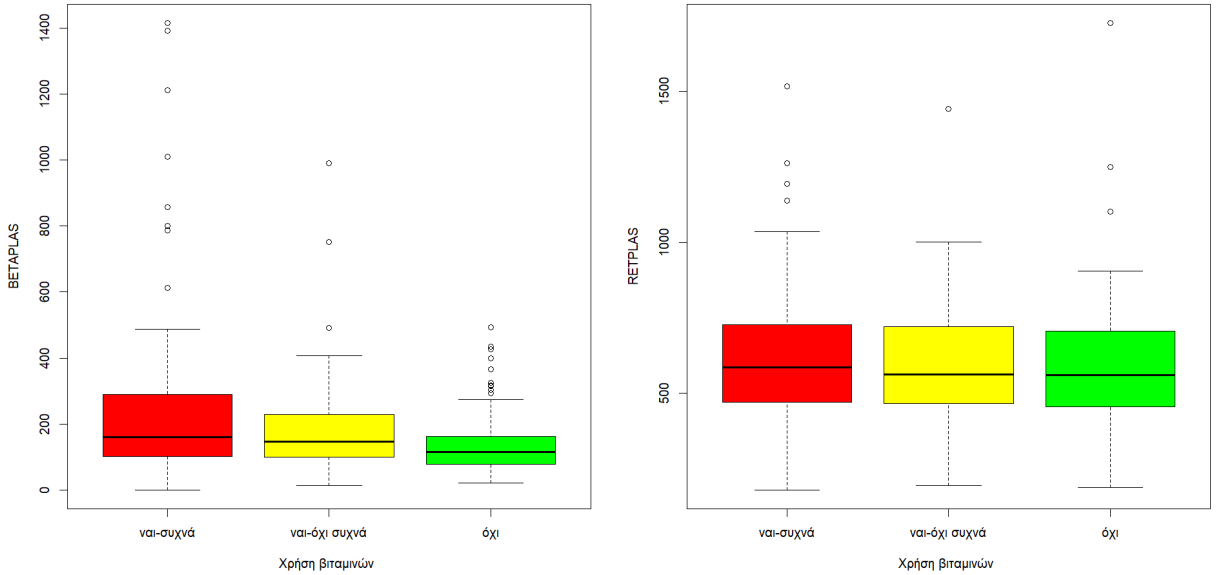

Διάγραμμα 3: Χρήση βιταμινών

4 Προβλεπτικά ή Ερμηνευτικά μοντέλα

Αφού εξετάσαμε στο προηγούμενο κεφάλαιο τις σχέσεις μεταξύ των μεταβλητών ανά δύο και το πώς σχετίζονται μεταξύ τους, προχωράμε στη δημιουργία δυο διαφορετικων προβλεπτικων μοντέλων για τον κίνδυνο εμφάνισης καρκίνου από τα επίπεδα της βήτα-καροτίνης και της ρετινόλης στο αίμα. Αρχικά, επιλέγουμε ως εξαρτημένη μεταβλητή τη βήτα-καροτίνη. Για να μπορέσουμε να διαπιστώσουμε εάν το μοντέλο είναι έγκυρο, πρέπει να εξετάσουμε εάν ικανοποιούνται οι υποθέσεις της πολυσυγγραμμικότητας, της κανονικότητας και της ομοσκεδαστικότητας.

Πίνακας 5: Πολυσυγγραμμικότητα μεταβλητών με εξαρτημένη την BETAPLAS

Μεταβλητή	**GVIF**	**Df**	$GVIF^{1/(2\cdot Df)}$
AGE	1.336020	1	1.155863
SEX	1.314534	1	1.146531
SMOKSTAT	1.194283	2	1.045386
BMI	1.068345	1	1.033608
VITUSE	1.147825	2	1.035068
CALORIES	13.314201	1	3.648863
FAT	8.261974	1	2.874365
FIBER	2.199133	1	1.482947
ALCOHOL	2.573605	1	1.604246
CHOLESTE	2.189738	1	1.479776
RETPLAS	1.107597	1	1.052424

Από τον Πίνακα 5 μπορούμε εύκολα να παρατηρήσουμε ότι υπάρχει πρόβλημα πολυσυγγραμμικότητας, εφόσον η μεταβλητή CALORIES > 10. Άρα, για τον έλεγχο της κανονικότητας και της ομοσκεδαστικότητας, θα αφαιρέσουμε τη μεταβλητή CALORIES. Ειδικότερα, παρατηρούμε ότι το μοντέλο δεν ακολουθεί την κανονική κατανομή (W = 0.71269, p-value < 2.2e-16) και παρουσιάζει ετεροσκεδαστικότητα .

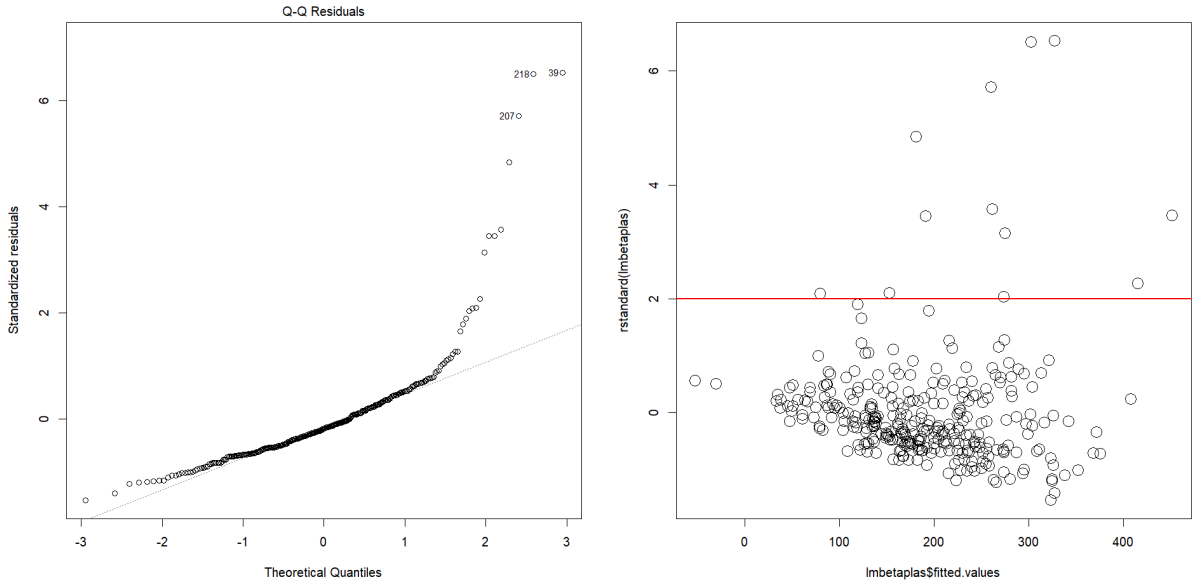

Διάγραμμα 4: Διάγραμμα έλεγχου κανονικότητας και ομοσκεδαστικότητας βήτα καροτίνης

Λόγω της παραβίασης των υποθέσεων, έγινε λογαριθμικός μετασχηματισμός στην Βήτα-καροτίνη. Το νέο μοντέλο παρουσίασε σημαντική βελτίωση στην κανονικότητα (W = 0.98824, p-value = 0.01247) και στην ετεροσκεδαστικότητα.

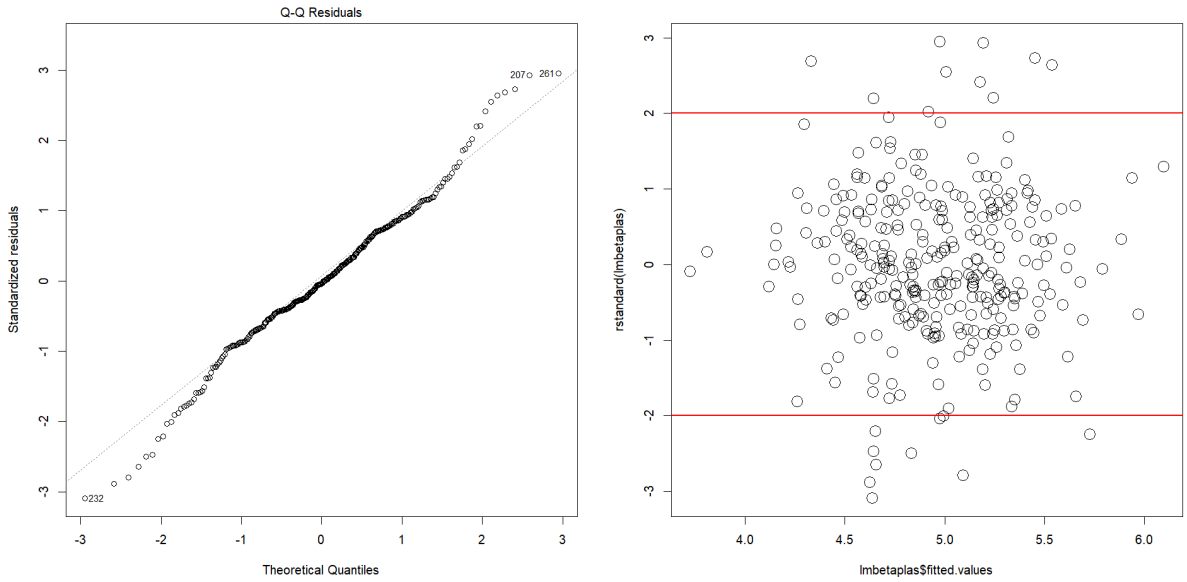

Διάγραμμα 5: Διάγραμμα έλεγχου κανονικότητας και ομοσκεδαστικότητας log βήτα καροτίνης

Κατά την ανάλυση, παρατηρήθηκε μέσω του δείκτη Cook μια ακραία τιμή (παρατήρηση 61), η οποία αφορά έναν άνδρα 65 ετών, μη καπνιστή.Ο συγκεκριμένος ασθενής ανέφερε υπερβολικά υψηλή καθημερινή κατανάλωση θερμίδων (6.662),όπως και υπερβολικά υψηλό αριθμό οινοπνευματωδών ποτών (203).Αυτό μας οδήγησε να αφαιρέσουμε την ακραία αυτή τιμή, κάτι που όμως δεν οδήγησε σε σημαντική βελτίωση του μοντέλου.

Πίνακας 6: Σύγκριση παλινδρομήσεων BETAPLAS

	LOG-BETAPLAS			LOG-BETAPLAS (χωρίς ακραία τιμή)		
Variable	**Estimate**	**Std. Error**	**p value**	**Estimate**	**Std. Error**	**p value**
(Intercept)	4.9700	0.3379	<0.0001	4.9840	0.3398	<0.0001
AGE	0.0054	0.0028	0.0587	0.0053	0.0029	0.0661
SEXΓυναίκα	0.2921	0.1257	0.0208	0.2855	0.1268	0.0251
SMOKSTATπρώην καπνιστ-ής/-ρια	-0.1008	0.0840	0.2309	-0.0963	0.0848	0.2568
SMOKSTATκαπνιστ-ής/-ρια	-0.2966	0.1213	0.0151	-0.2978	0.1215	0.0148
BMI	-0.0318	0.0064	0.0000	-0.0322	0.0065	0.0000
VITUSEΕίναι-όχι συχνά	-0.0274	0.0964	0.7764	-0.0247	0.0967	0.7982
VITUSEόχι	-0.2766	0.0900	0.0023	-0.2725	0.0906	0.0029
FAT	-0.0015	0.0017	0.3791	-0.0014	0.0017	0.3918
FIBER	0.0302	0.0076	0.0001	0.0301	0.0076	0.0001
ALCOHOL	0.0019	0.0032	0.5574	-0.0014	0.0082	0.8616
CHOLESTE	-0.0003	0.0004	0.5053	-0.0003	0.0004	0.5004
RETPLAS	0.0004	0.0002	0.0190	0.0005	0.0002	0.0174

Residual Std. Error: 0.6598 (df = 300) / 0.6607 (df = 299)
R^2*:* 0.2532 / 0.253
R^2*adj:* 0.2233 / 0.223

Αναλυτικότερα, αρκετές μεταβλητές παρουσίασαν σημαντική επίδραση τόσο στο αρχικό μοντέλο, όσο και σε αυτό το οποίο είχαμε αφαιρέσει την ακραία τιμή (παρατήρηση 61). Συγκεκριμένα, το φύλο, το κάπνισμα, η χρήση βιταμινών, ο δείκτης μάζας σώματος, η πρόσληψη φυτικών ινών και τα επίπεδα ρετινόλης στο πλάσμα επηρέασαν τα επίπεδα β-καροτίνης στο πλάσμα. Το φύλο εμφάνισε θετική επίδραση στο μοντέλο, και συγκεκριμένα οι γυναίκες έχουν υψηλότερα επίπεδα β-καροτίνης από ό,τι έχουν οι άνδρες. Επιπλέον, η μεταβλητή FIBER, όπως και η ρετινόλη, σχετίζονται και αυτές θετικά με τα επίπεδα β-καροτίνης στο αίμα. Αντιθέτως, το κάπνισμα, η μη χρήση βιταμινών και ο δείκτης μάζας σώματος συσχετίστηκαν αρνητικά με τη β-καροτίνη, οδηγώντας σε μείωση των επιπέδων της στο πλάσμα.

Αντίστοιχη προσέγγιση θα ακολουθήσουμε και για τη ρετινόλη. Παρατηρούμε πως και αυτή η μεταβλητή παραβιάζει την πολυσυγγραμμικότητα, εφόσον η μεταβλητή CALORIES > 10. Άρα, για τον έλεγχο της κανονικότητας και της ομοσκεδαστικότητας, θα αφαιρέσουμε τη μεταβλητή CALORIES.

Πίνακας 7: Πολυσυγγραμμικότητα μεταβλητών με εξαρτημενη την RETPLAS

Μεταβλητή	**GVIF**	**Df**	**GVIF**$^{1/(2\cdot Df)}$
AGE	1.222676	1	1.105747
SEX	1.293274	1	1.137222
SMOKSTAT	1.188065	2	1.044023
BMI	1.121581	1	1.059047
VITUSE	1.159636	2	1.037721
FAT	2.200906	1	1.483545
FIBER	1.225550	1	1.107046
ALCOHOL	1.145652	1	1.070351
CHOLESTE	2.075365	1	1.440613
BETAPLAS	1.221071	1	1.105021

Επίσης,παρατηρουμε πως δεν ακολουθεί την κανονική κατανομή, αφού ο έλεγχος Shapiro-Wilk έδωσε (W = 0.94139, p-value = 7.967e-10) αλλα εμφανιζει ομοσκεδαστικοτητα .

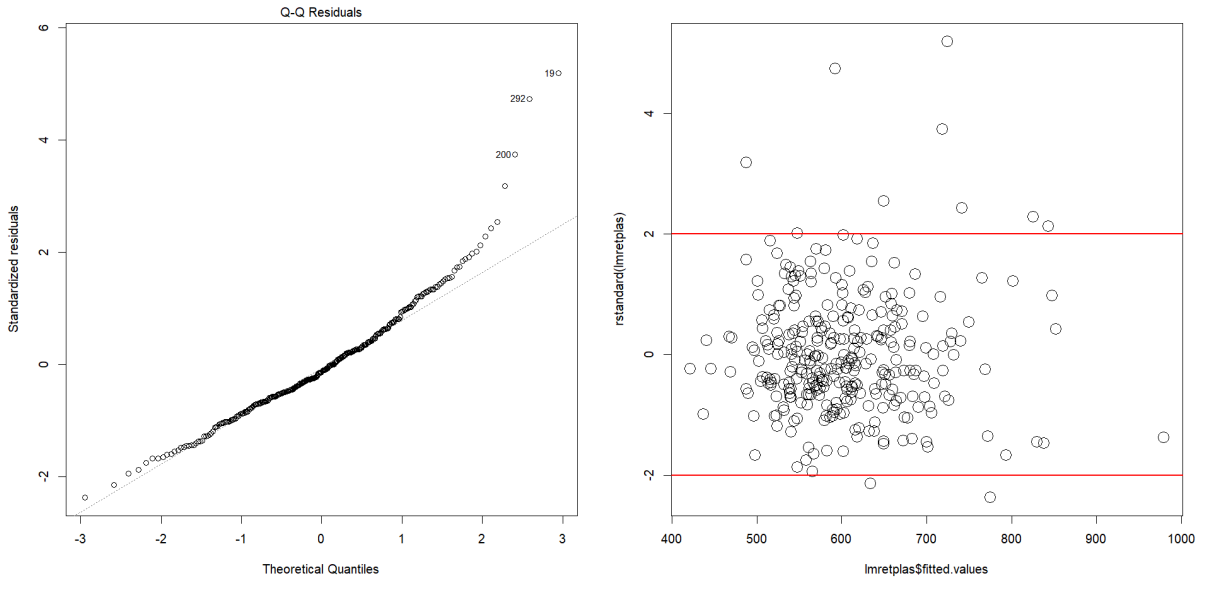

Διάγραμμα 6: Ιστογραμματα για τα επιπεδα RETPLAS και BETAPLAS ανά φύλο

Αφαιρώντας πάλι την ακραία τιμή μέσω του δείκτη Cook (παρατήρηση 61), το μοντέλο παρουσίασε σημαντική βελτίωση. Στη συνέχεια, παρατηρούμε πως το μοντέλο παρουσιάζει νέες ακραίες τιμές (παρατηρήσεις 19 και 295).

Η παρατήρηση 19 αφορά έναν ασθενή, άνδρα 57 ετών, πρώην καπνιστή, ο οποίος δεν κάνει χρήση βιταμινών. Ο ασθενής αυτός καταναλώνει καθημερινά 1101,4 θερμίδες, 48,5 γρ. λίπους και 8,5 γρ. φυτικών ινών. Τα επίπεδα χοληστερόλης του είναι 197,2 mg, τα επίπεδα β-καροτίνης 113 ng/ml και της ρετινόλης 1727 ng/ml.

Από την άλλη, η παρατήρηση 295 αφορά έναν ασθενή, άνδρα 41 ετών, ο οποίος είναι καπνιστής και κάνει χρήση βιταμινών. Ο ασθενής αυτός καταναλώνει καθημερινά 2685,1 θερμίδες, 133,1 γρ. λίπους και 11,1 γρ. φυτικών ινών. Τα επίπεδα χοληστερόλης του είναι 432,4 mg, τα επίπεδα β-καροτίνης 63 ng/ml και της ρετινόλης 1193 ng/ml.

Πίνακας 8: Σύγκριση παλινδρομήσεων RETPLAS

Μεταβλητή	**Μοντέλο 1**	**Μοντέλο 2**	**Μοντέλο 3**
(Intercept)	533.26 ($p < 0.001$)	485.09 ($p < 0.001$)	483.92 ($p < 0.001$)
AGE	2.26 ($p = 0.0079$)	2.41 ($p = 0.0032$)	2.44 ($p = 0.0031$)
SEX (Γυναίκα)	-82.85 ($p = 0.028$)	-55.04 ($p = 0.131$)	-54.48 ($p = 0.136$)
SMOKSTAT (Πρώην)	42.90 ($p = 0.089$)	35.93 ($p = 0.137$)	36.37 ($p = 0.134$)
SMOKSTAT (Νυν)	4.38 ($p = 0.904$)	7.75 ($p = 0.824$)	7.82 ($p = 0.823$)
BMI	2.28 ($p = 0.247$)	2.36 ($p = 0.209$)	2.36 ($p = 0.210$)
VITUSE (Ναι-όχι συχνά)	-4.30 ($p = 0.882$)	-4.91 ($p = 0.859$)	-4.31 ($p = 0.877$)
VITUSE (Όχι)	-34.56 ($p = 0.210$)	-41.22 ($p = 0.118$)	-41.35 ($p = 0.118$)
FAT	-0.40 ($p = 0.418$)	-0.27 ($p = 0.562$)	-0.28 ($p = 0.553$)
FIBER	-1.79 ($p = 0.442$)	-1.42 ($p = 0.521$)	-1.45 ($p = 0.515$)
ALCOHOL	8.50 ($p < 0.001$)	8.75 ($p < 0.001$)	8.80 ($p < 0.001$)
CHOLESTE	-0.067 ($p = 0.584$)	-0.065 ($p = 0.581$)	-0.064 ($p = 0.588$)
BETAPLAS	0.068 ($p = 0.312$)	0.068 ($p = 0.292$)	0.068 ($p = 0.295$)
Residual Std. Error	197.4	188.8	189.1
R^2	0.1357	0.1303	0.1295
R^2 adj	0.1011	0.0954	0.0944

Από τον Πίνακα 8 μπορούμε εύκολα να παρατηρήσουμε πως το μοντέλο, μετά την αφαίρεση της ακραίας τιμής 295, σταθεροποιείται. Επομένως, δεν υπάρχει λόγος στην περαιτέρω αφαίρεση της ακραίας τιμής 200 στο Μοντέλο 3. Η μεταβλητή AGE και η ALCOHOL παραμένουν σταθερά σημαντικές, καθώς $p < 0.01$. Αντίθετα, οι μεταβλητές

SEX, SMOKESTAT, BMI, FIBER, VITUSE και BETAPLAS δεν παρουσιάζουν στατιστική σημαντικότητα στο μοντέλο.Άρα, εύλογα καταλήγουμε στο συμπέρασμα ότι μόνο η ηλικία και η κατανάλωση αλκοόλ επηρεάζουν τα επίπεδα ρετινόλης στο πλάσμα του αίματος.

5 Συμπεράσματα

Η παραπάνω μελέτη είχε ως σκοπό να μελετήσει ευρήματα που δείχνουν ότι διατροφή φτωχή σε ρετινόλη και βήτα-καροτίνη δημιουργεί αυξημένο κίνδυνο ανάπτυξης ορισμένων τύπων καρκίνου.Τα μοντέλα μας δεν έχουν πολύ καλή προσαρμογή ($R^2adj = 0.23$ και $R^2adj = 0.101$), αλλά υποδεικνύουν ότι η ηλικία και η κατανάλωση αλκοόλ επηρεάζουν σημαντικά τα επίπεδα ρετινόλης και βήτα-καροτίνης. Καταλήγουμε, λοιπόν, στο συμπέρασμα ότι μια ισορροπημένη διατροφή, αλλά και ένας υγιεινός τρόπος ζωής, επηρεάζουν θετικά τα επίπεδα βήτα-καροτίνης και ρετινόλης στο αίμα.

6 Παράρτημα

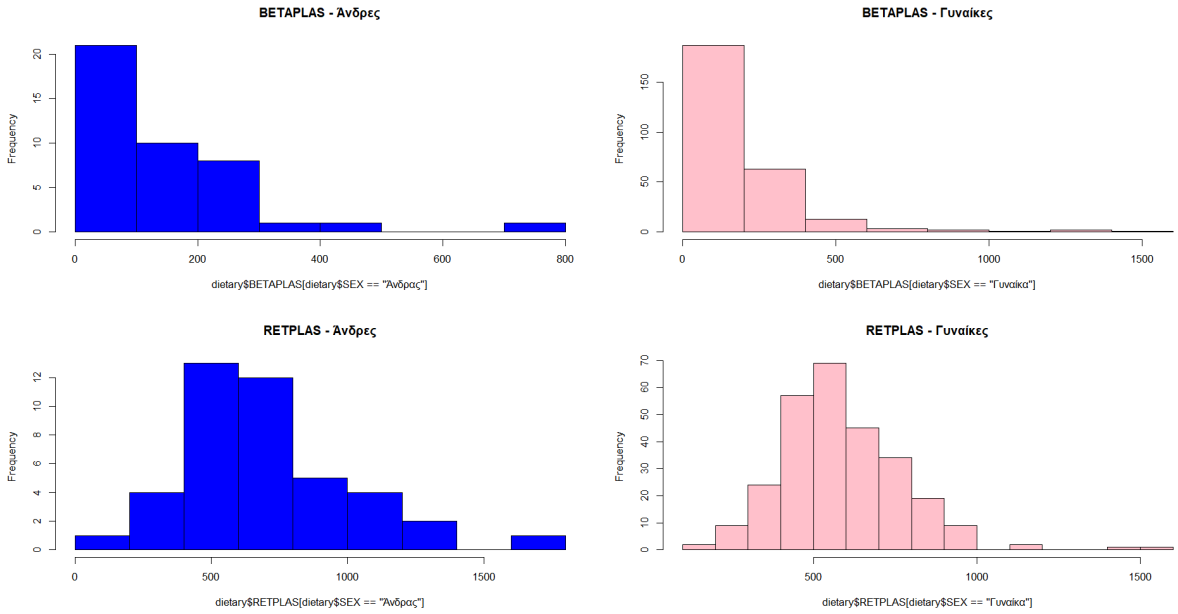

Διάγραμμα 7: Ιστογραμματα για τα επιπεδα RETPLAS και BETAPLAS ανά φύλο

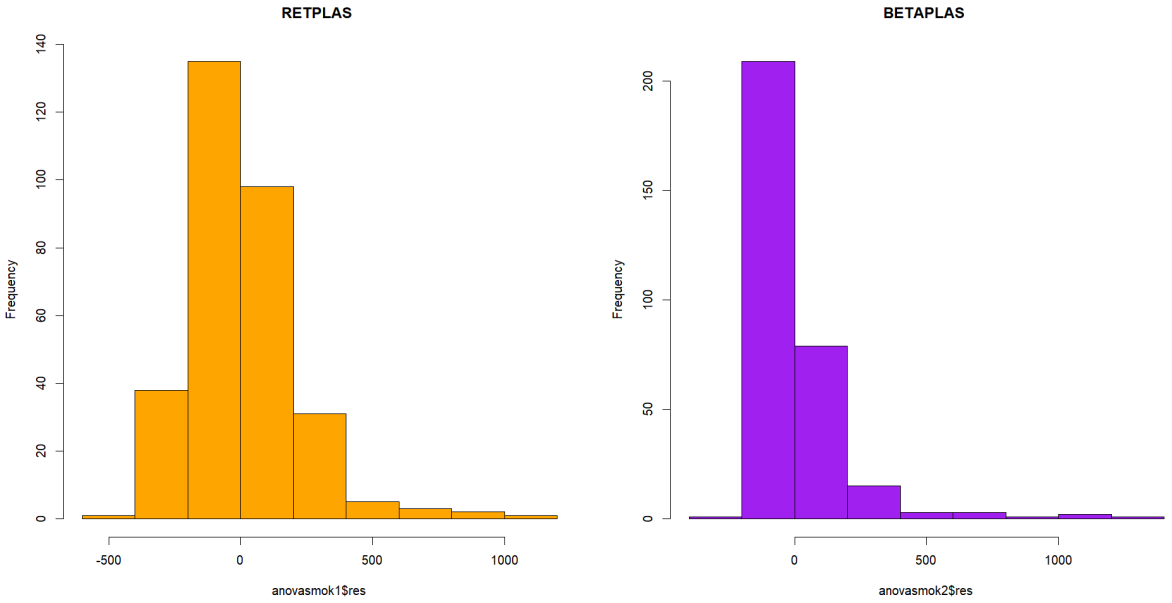

Διάγραμμα 8: Ιστογραμματα για τα επιπεδα RETPLAS και BETAPLAS για την μεταβλητη SMOKSTAT

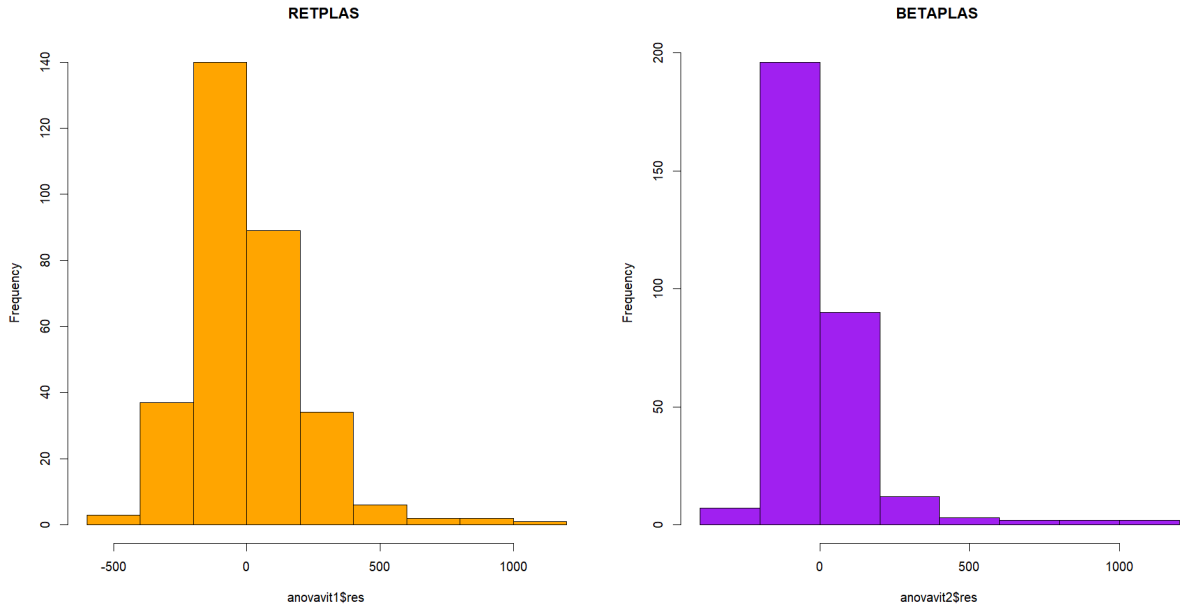

Διάγραμμα 9: Ιστογραμματα για τα επιπεδα RETPLAS και BETAPLAS για την μεταβλητη VITUSE

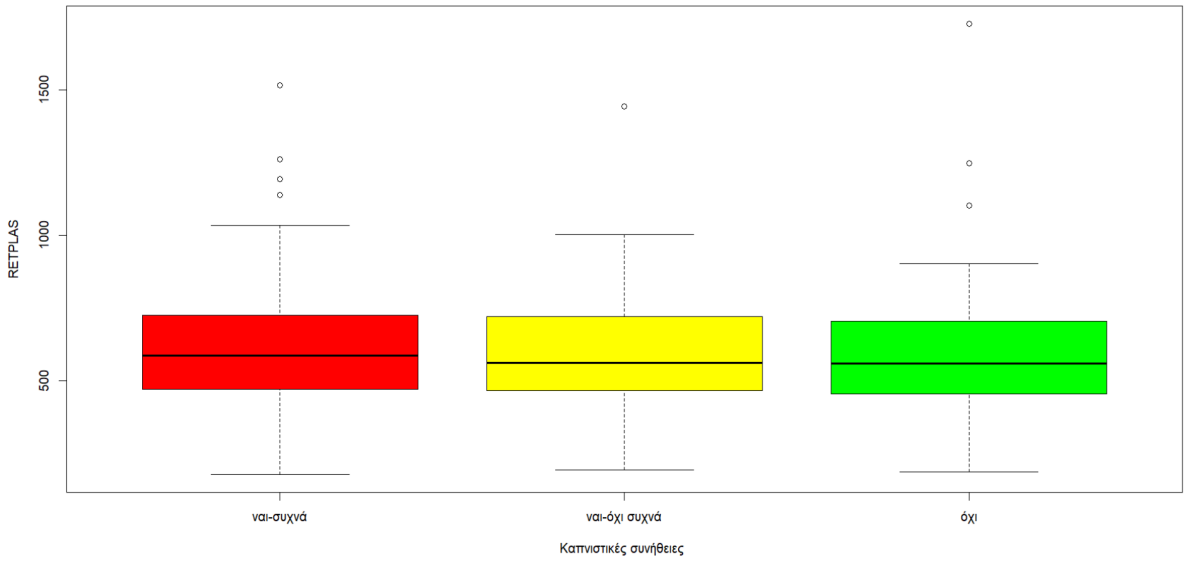

Διάγραμμα 10: Boxplot για τα επιπεδα BETAPLAS για την μεταβλητη VITUSE

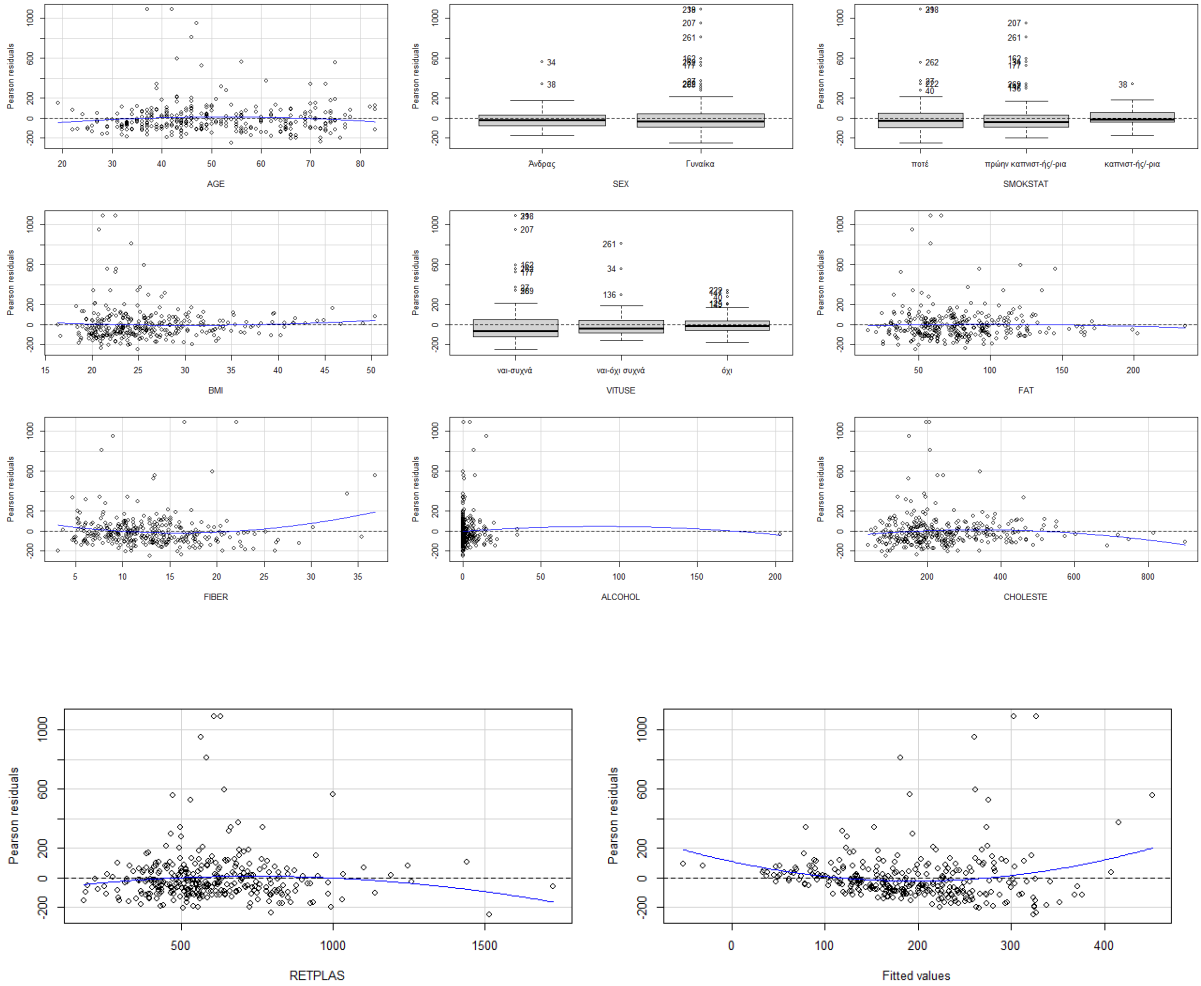

Διάγραμμα 11: Διάγραμμα καταλοίπων Pearson ως προς τις ανεξάρτητες μεταβλητές

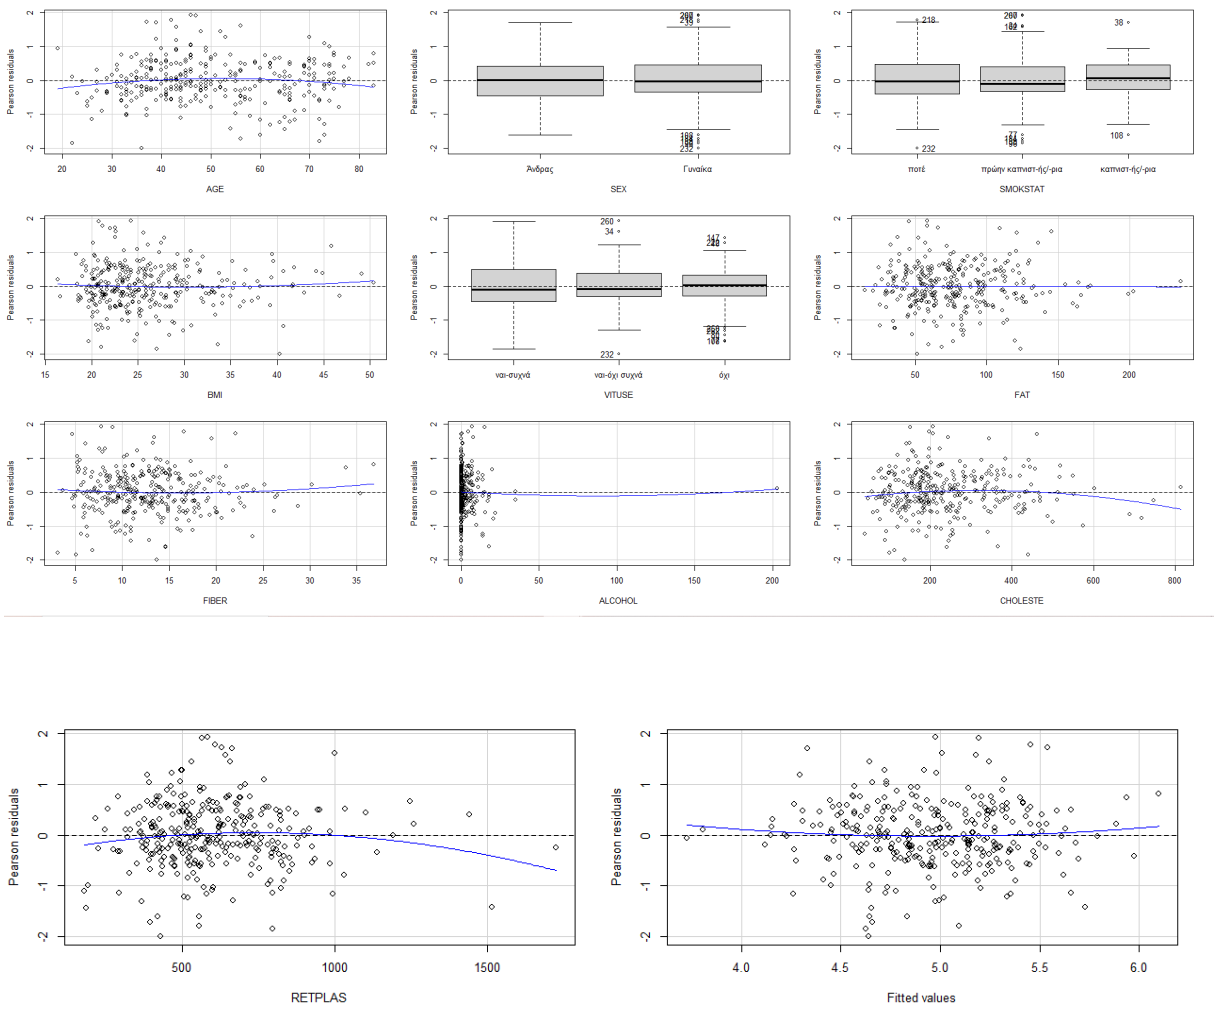

Διάγραμμα 12: Λογαριθμημένο Διάγραμμα καταλοίπων Pearson ως προς τις ανεξάρτητες μεταβλητές

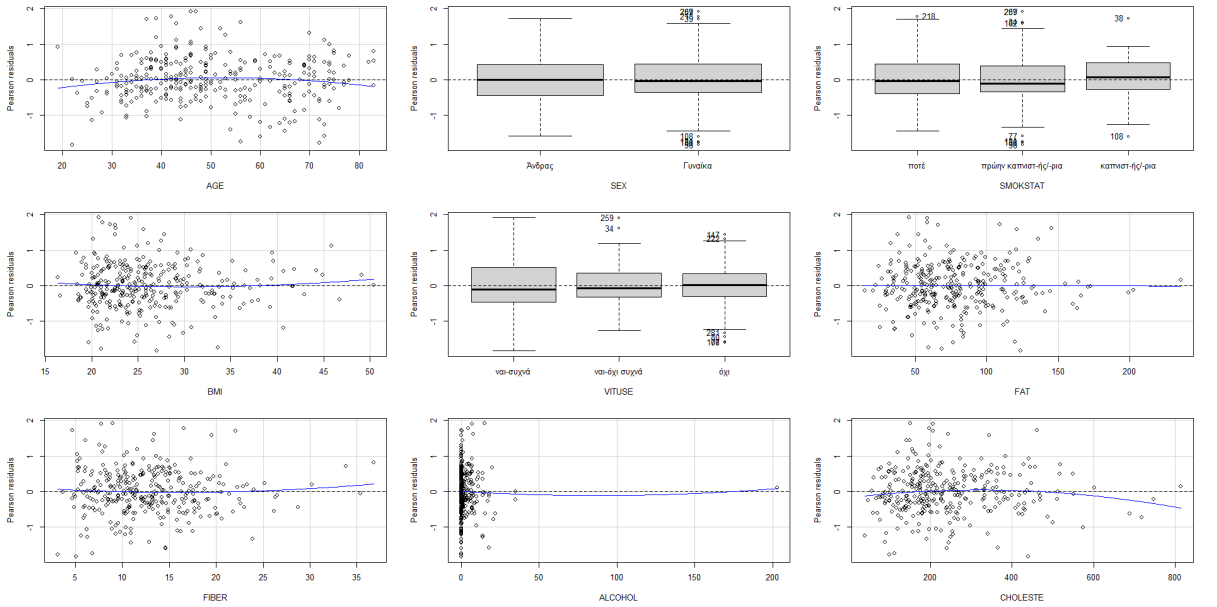

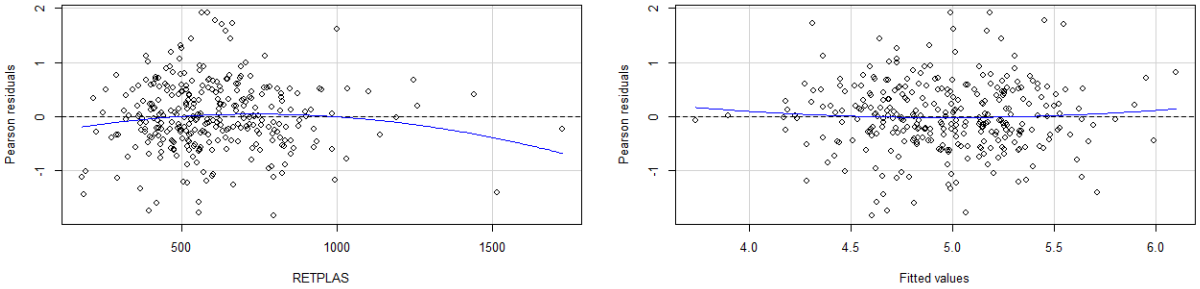

Διάγραμμα 13: Λογαριθμημένο Διάγραμμα καταλοίπων Pearson ως προς τις ανεξάρτητες μεταβλητές χωρις την ακραία παρατήρηση

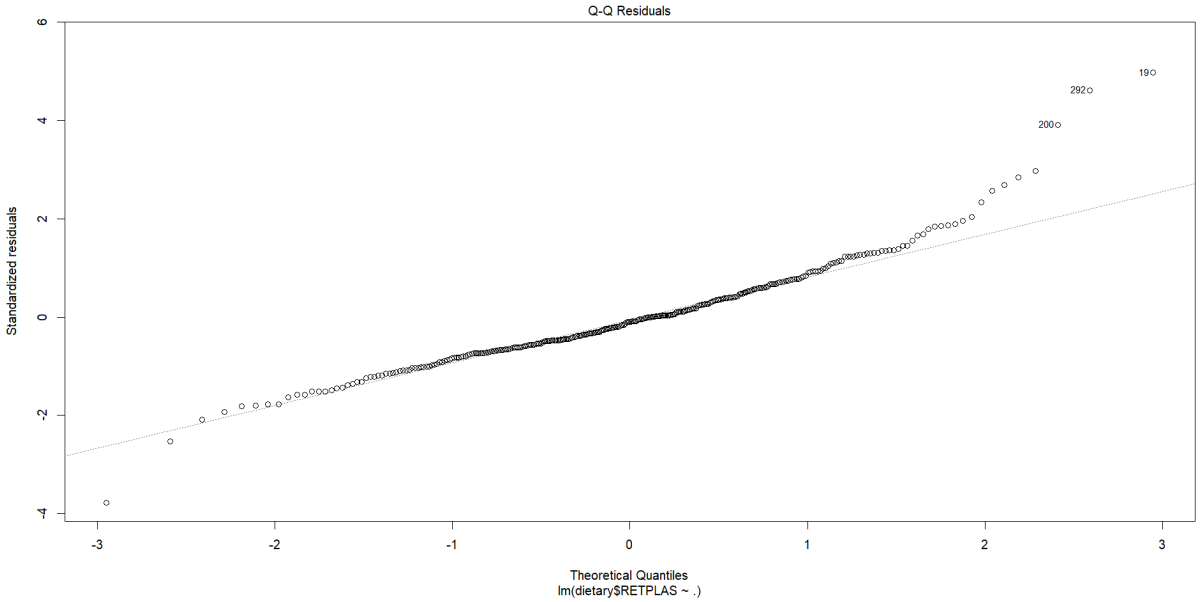

Διάγραμμα 14: Διάγραμμα έλεγχου κανονικότητας

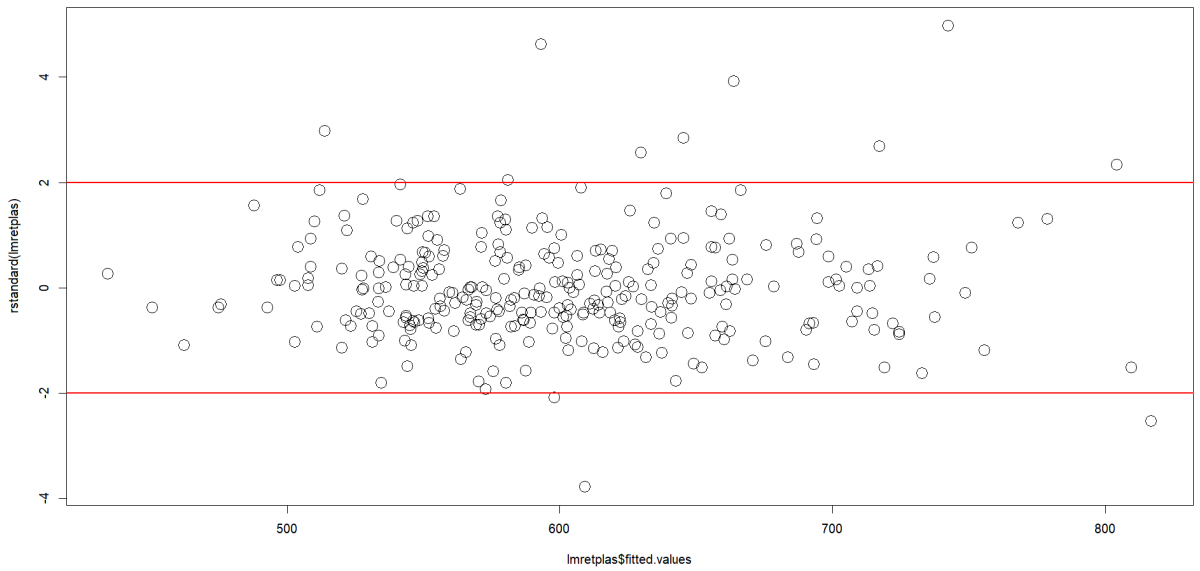

Διάγραμμα 15: Διάγραμμα έλεγχου ομοσκεδαστικοτητας

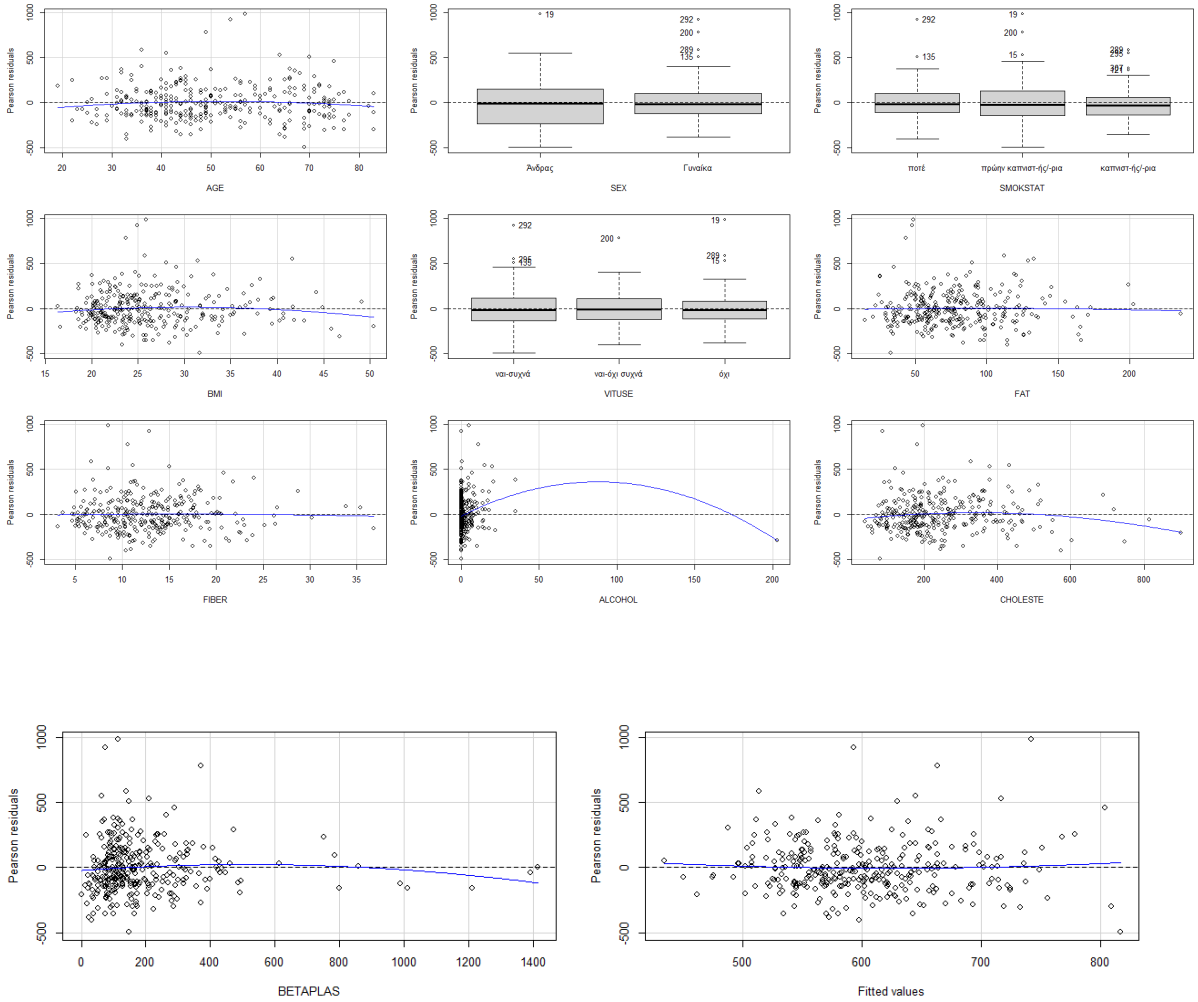

Διάγραμμα 16: Διάγραμμα καταλοίπων Pearson ως προς τις ανεξάρτητες μεταβλητές

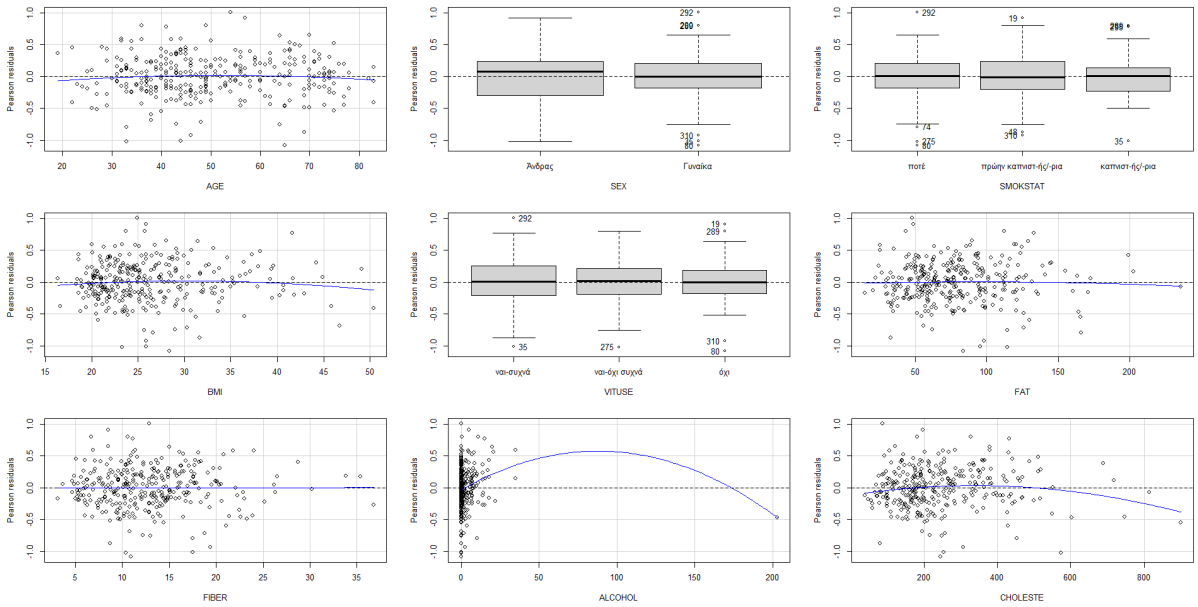

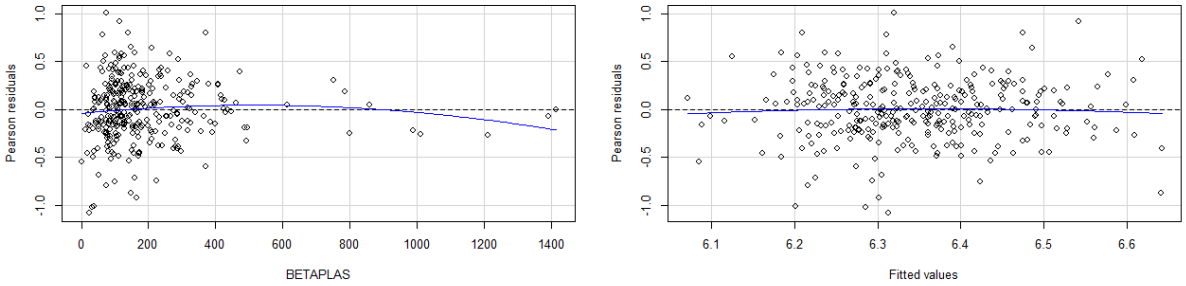

Διάγραμμα 17: Λογαριθμημένο Διάγραμμα καταλοίπων Pearson ως προς τις ανεξάρτητες μεταβλητές

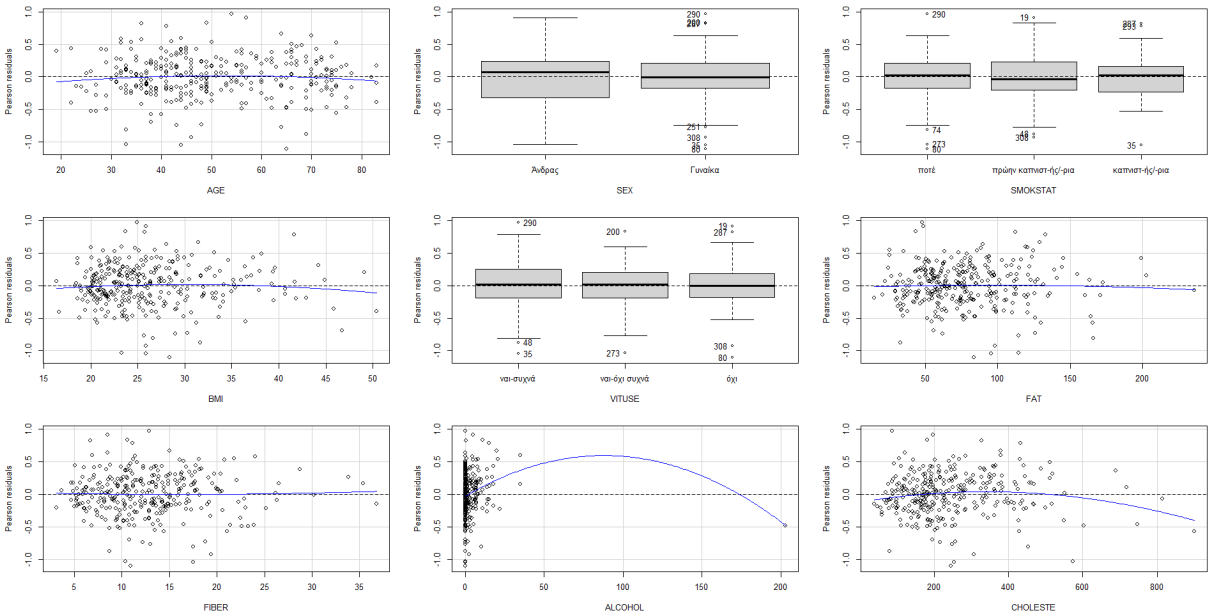

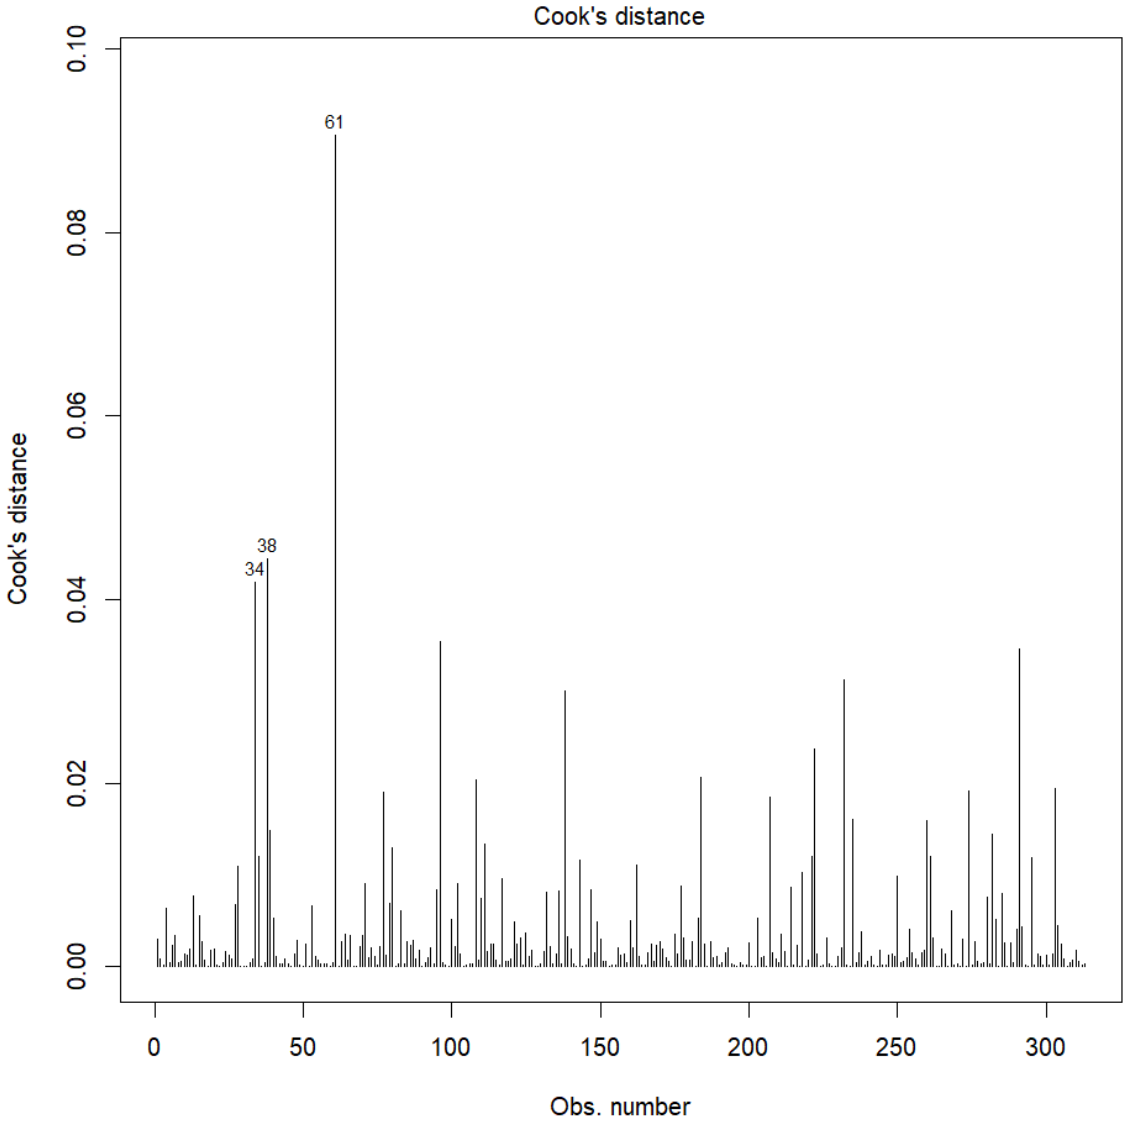

Διάγραμμα 18: Ελεγχος Cook για το BETAPLAS

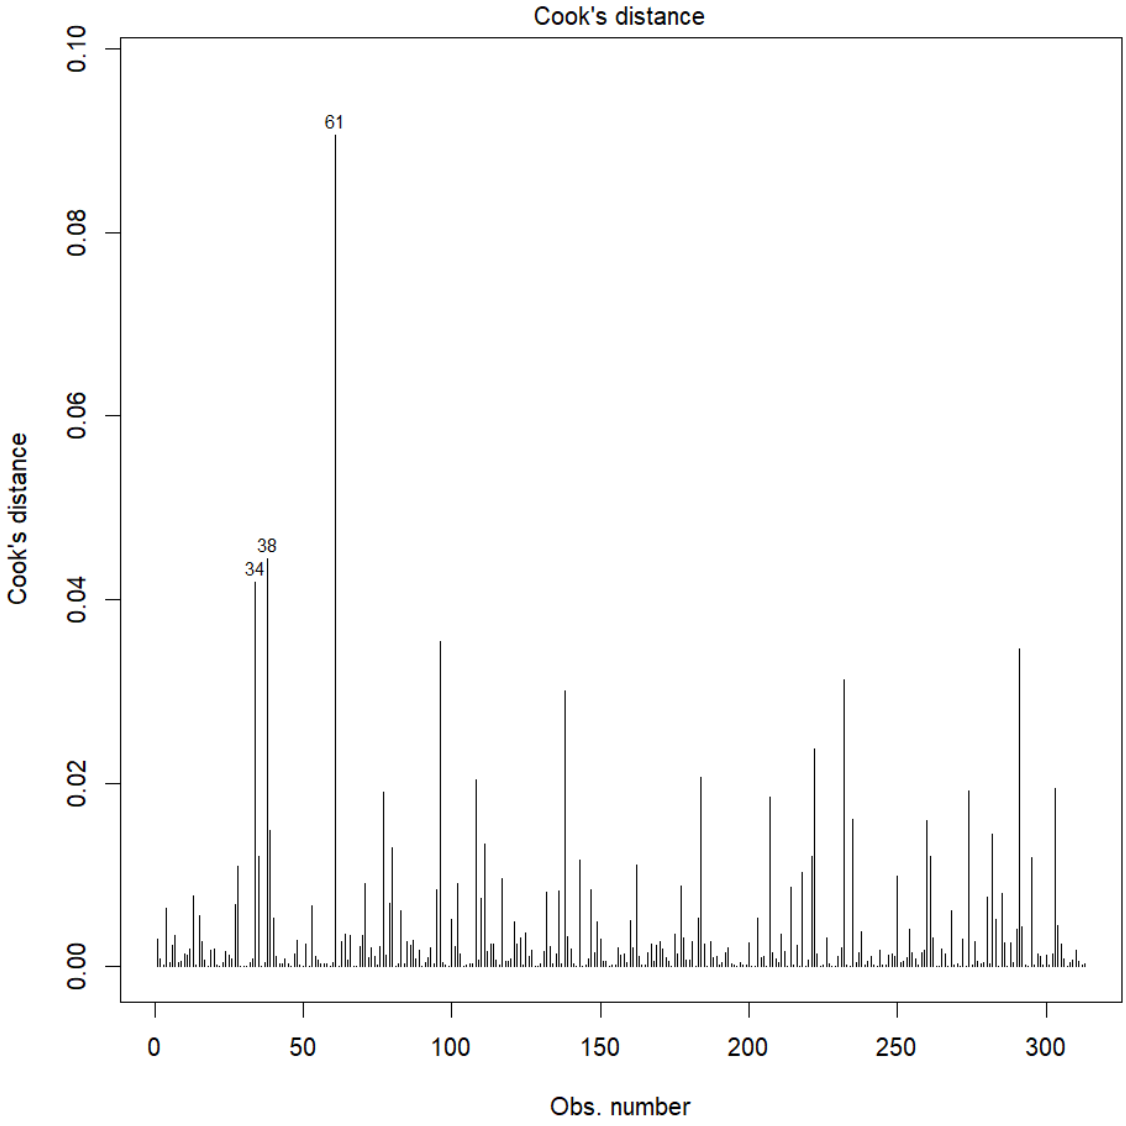

Διάγραμμα 19: Ελεγχος Cook για το RETPLAS

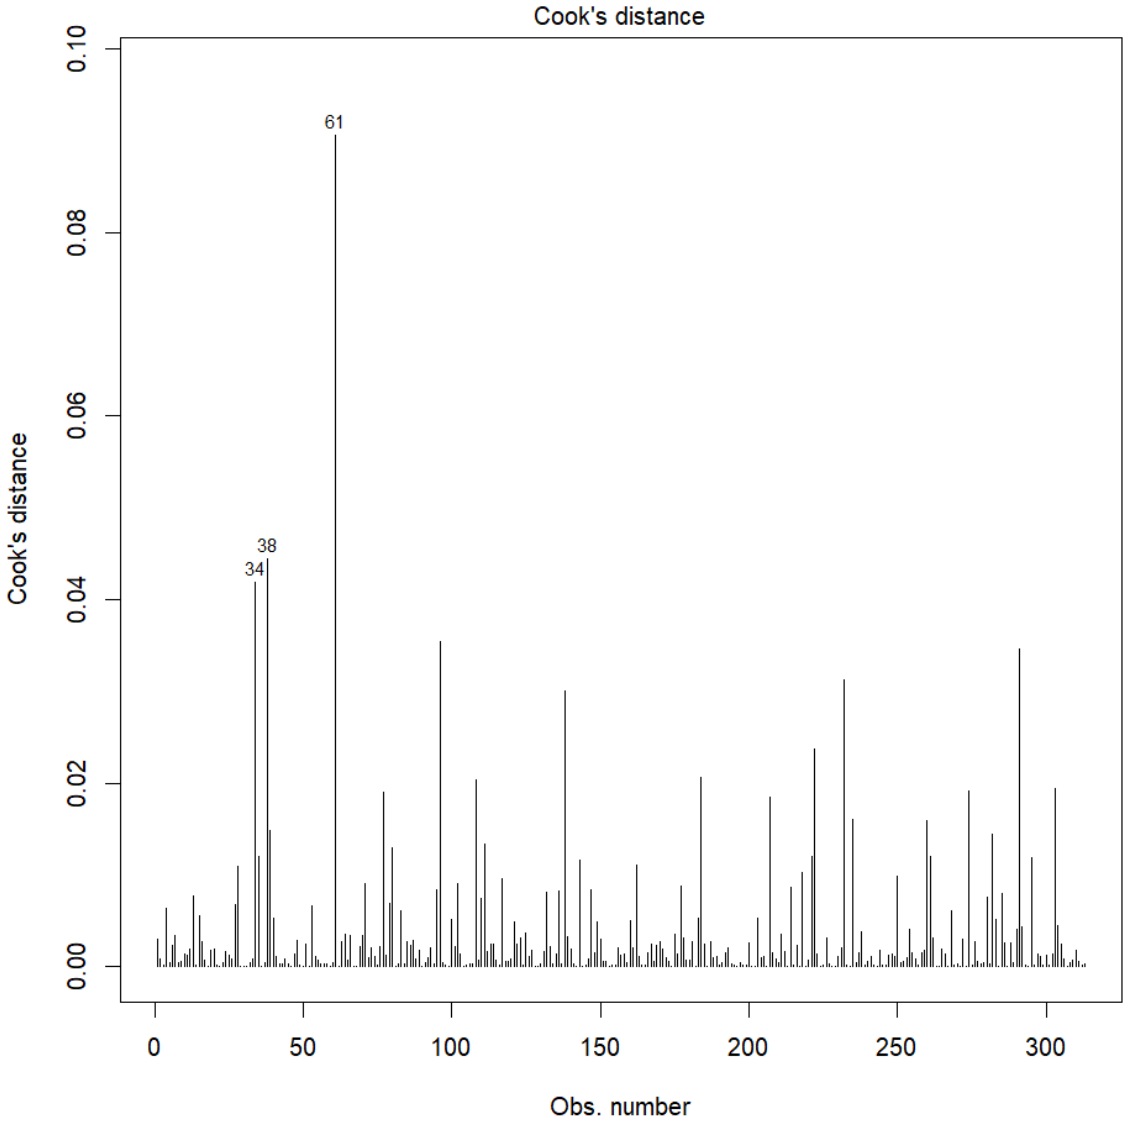

Διάγραμμα 20: Έλεγχος Cook για το RETPLAS ενώ έχω αφαιρέσει παρατήρηση 61